

Actividad Construye | MLflow Project y tracking avanzado | Colaborativo

Integrantes del Equipo

Daniela Montserrat Enríquez Ballesteros (A01797865)

Humberto Alejandro Espinola González (A01840066)

Oscar Alejandro Torres Maya (A01377686)

Humberto Carrillo Gómez – (A01377246)

MNA – Operaciones de aprendizaje automático

Profesor Titular: Dr. Iván Reyes Amezcua

Fecha de entrega: 25 de Octubre de 2026

Cisco Confidential

Experimentación y ciclo de vida de modelos MiBici

TC5061 MLOps — Equipo 27 — Partes B y C

Este reporte presenta la comparación de modelos para demanda, riesgo de desequilibrio y agrupación de estaciones, así como su registro en MLflow. P1 mejora el error frente al baseline; P2 y P3 presentan resultados mixtos que limitan su uso operativo. Se selecciona con validación y se conserva la prueba para la evaluación final.

Repositorio: https://github.com/hespinola/TC5061-Proyecto-Equipo27

Resultado	**Evidencia**
Experimentación	4 baselines repetidos, 9 candidatas y 3 búsquedas anidadas; todos los runs de la suite final terminaron.
Reproducibilidad	Paridad numérica de los cuatro baselines y misma versión de datos que la entrega anterior.
Registry	3 modelos, versión 1, alias champion; carga por nombre y paridad de predicciones verificadas.
Validación documentada	La bitácora de la ejecución original reporta 50 pruebas locales y ejecución mediante mlflow run con SQLite.

La parte A se integró en main mediante el PR #10. La parte C se desarrolló en feat/mlflow-registry y se integró en feat/mlflow-experiments mediante el PR #12.

1 Datos diseño y reproducibilidad

Se reutilizaron los Parquet locales de la primera entrega, verificados contra el manifiesto versionado; no se alteraron las fuentes ni se descargó una nueva versión en esta ejecución. La reconstrucción produjo 4,125,960 filas de estación por hora, 471 estaciones y 4,497,119 viajes válidos. Los datos individuales y modelos serializados no forman parte de Git.

Partición	**Periodo**	**Criterio**
Train	2025-10-01 a 2026-06-30	Ajuste de modelos, escalado y PCA.
Validación	2026-07-01 a 2026-07-31	Selección de combinación y umbral P2.
Prueba	2026-08-01 a 2026-09-30	Comparación final; nunca decide modelo o umbral.

Los predictores de t solo usan horas anteriores a t. Se mantiene el calentamiento de 168 h. P2 excluye etiquetas cuya ventana de tres horas cruza el corte de la partición y estaciones sin capacidad válida. P1 evalúa 350,424 filas de validación y 689,544 de prueba; P2 evalúa 347,998 y 685,678, respectivamente.

Versión SHA-256 de los datos:

`ea4e65629d4c5f0565956bdb37c17920b8529a7a1308fd6ba7ecb74429f231d1`

Commit de entrenamiento: 9cd40eb0af9feed8bcbf6048a74292e04b8709c2

Corrida Project: 580a6efc0ebd4aea97160d1a40dc1e75

Cisco Confidential

Los nuevos baselines se cotejaron contra baseline_results.json de la entrega anterior, incluidas métricas y conteos, con tolerancia relativa 1e-9. El resumen enlaza cada ID nuevo con su ID original. Se conservaron los archivos históricos y los mismos nombres de métricas.

Entorno usado: Python 3.13.9, MLflow 3.17.1 y scikit-learn 1.9.1; demás versiones fijas en requirements.txt y python_env.yaml. La ejecución usó el entorno ya instalado mediante --env-manager local. La bitácora original no documenta una reinstalación ni una descarga nueva de los datos en esa ejecución.

2 Comandos para reproducir

El repositorio contiene MLproject y python_env.yaml. Los valores de rutas, fechas y semilla se resuelven desde config.py. Se requiere Python 3.13 y las dependencias fijas de tec-mlops-equipo-27/requirements.txt. La instalación completa para Bash y PowerShell se encuentra en el README.

Desde la raíz del clon que contiene B y C, iniciar el servidor en una terminal con el entorno activado:

```
mlflow server --backend-store-uri sqlite:///mlflow.db --host 127.0.0.1 --port 5000
```

En otra terminal PowerShell con el mismo entorno, ejecutar:

```
$env:MLFLOW_TRACKING_URI = "http://127.0.0.1:5000"
$env:MLFLOW_EXPERIMENT_NAME = "mibici-equipo27"
mlflow run . -e ingest --env-manager local
mlflow run . -e experiment --env-manager local
mlflow run . -e register --env-manager local
```

En Bash, sustituir las asignaciones por export MLFLOW_TRACKING_URI=http://127.0.0.1:5000 y export MLFLOW_EXPERIMENT_NAME=mibici-equipo27. Mientras B no esté integrada en main, utilizar feat/mlflow-experiments, que ya contiene C. Mantener activo el servidor y usar siempre la misma carpeta para su base SQLite.

Para repetir individualmente los modelos elegidos en Bash (en PowerShell, escribir cada comando en una sola línea sin las barras de continuación):

```
mlflow run . -e train --env-manager local -P question=p1 \
  -P model=hgb -P n_estimators=160 -P max_depth=8 -P learning_rate=0.08
mlflow run . -e train --env-manager local -P question=p2 \
  -P model=hgb -P n_estimators=160 -P max_depth=8 -P learning_rate=0.08
mlflow run . -e train --env-manager local -P question=p3 \
  -P model=pca_kmeans -P n_clusters=4 -P n_components=8
```

El código debe estar confirmado en Git. Los centinelas config resuelven rutas, cortes, semilla y valores por defecto desde config.py. Repetir la suite completa produce el resumen usado por register; las ejecuciones train individuales no reemplazan ese resumen. --env-manager uv crea el entorno declarado como alternativa.

Cisco Confidential

3 P1 Demanda por estación y hora

La métrica de selección es MAE de validación, en viajes por estación y hora. RMSE ayuda a observar errores grandes. Se comparan las dos referencias históricas y tres configuraciones de HistGradientBoostingRegressor. HGB se expresa como iteraciones/profundidad/tasa.

Modelo / parámetros	MAE val	RMSE val	MAE test	RMSE test	Mejora MAE test
Baseline 168 h	0.868982	1.824453	0.933745	1.921200	+0.00%
Baseline 24 h	0.910708	1.966678	1.035465	2.194621	-10.89%
HGB 60/4/0.1	0.740251	1.402308	0.816955	1.528955	+12.51%
HGB 100/6/0.1	0.721246	1.353892	0.799636	1.480837	+14.36%
HGB 160/8/0.08	0.719212	1.344548	0.797423	1.469569	+14.60%

Se elige HGB 160/8/0.08. Reduce el MAE de validación 17.24% y el de prueba 14.60% frente al rezago semanal. Las combinaciones de 100 y 160 iteraciones están dentro del margen de casi empate del 1%; la de 160 tiene menor dispersión semanal del MAE en validación (0.020376 frente a 0.021651).

El ajuste cuesta 12.63 s frente a 8.17 s para la alternativa de 100 iteraciones. El modelo ocupa 574,142 bytes y su latencia medida fue 0.003583 ms/fila en lotes de 1,000. Se acepta este costo por la menor dispersión y el menor error; el resultado no demuestra ahorros operativos. Los totales diarios de la figura son una visualización y no sustituyen la evaluación por estación y hora.

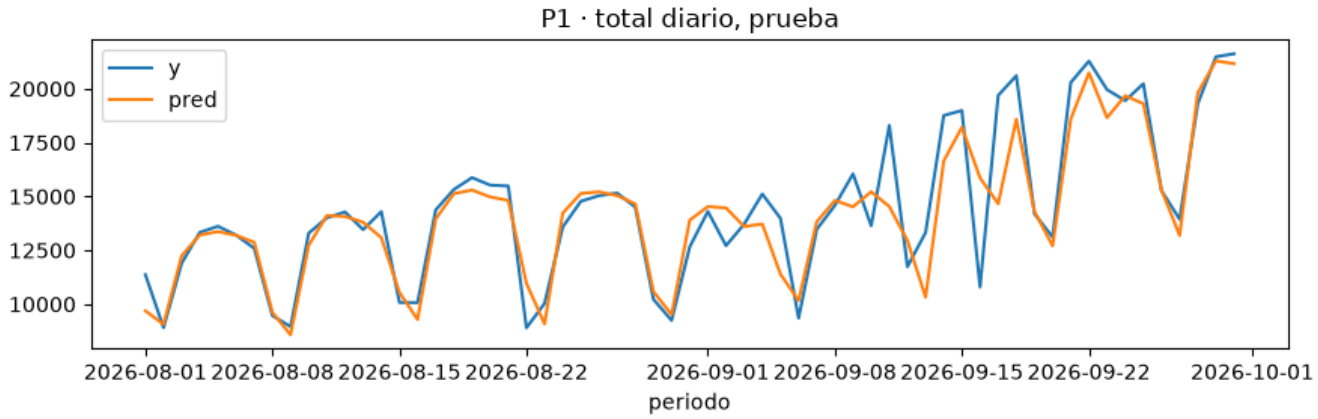


Figura 1. P1 observado y predicho en totales diarios de prueba.

Cisco Confidential

4 P2 Proxy de desequilibrio

HGB se expresa como iteraciones/profundidad/tasa de aprendizaje. Se maximiza average precision (AP) de validación para priorizar alertas en una clase rara. El umbral se elige por máximo F1 de validación dentro de la misma rejilla de la entrega anterior. El proxy es magnitud del flujo neto de tres horas >=50% de capacidad; no observa inventario real.

Validación

Modelo	AP	Precisión	Recall	F1	Umbral	Delta AP vs base
Baseline frecuencia	0.309132	0.403668	0.314783	0.353727	0.3	+0.00%
HGB 60/4/0.1	0.260849	0.296031	0.263439	0.278786	0.2	-15.62%
HGB 100/6/0.1	0.308868	0.358040	0.289628	0.320221	0.2	-0.09%
HGB 160/8/0.08	0.314710	0.369333	0.315817	0.340485	0.2	+1.80%

Prueba

Modelo	AP	Precisión	Recall	F1	Umbral	Delta AP vs base
Baseline frecuencia	0.325776	0.453065	0.269737	0.338152	0.3	+0.00%
HGB 60/4/0.1	0.279495	0.322827	0.280032	0.299911	0.2	-14.21%
HGB 100/6/0.1	0.315856	0.327547	0.348152	0.337535	0.2	-3.04%
HGB 160/8/0.08	0.318194	0.330378	0.371148	0.349578	0.2	-2.33%

Se elige HGB 160/8/0.08 con umbral 0.20: AP de validación 0.314710 frente a 0.309132 (+1.80%). No hay otra alternativa dentro del margen de casi empate del 1%. En prueba AP baja a 0.318194 frente a 0.325776 (-2.33%), pero recall sube de 0.269737 a 0.371148 y F1 de 0.338152 a 0.349578. La precisión cae de 0.453065 a 0.330378: se detectan más positivos a costa de más falsas alertas.

La selección se mantiene porque fue fijada con validación; la caída de AP en prueba impide afirmar una mejora general. El baseline sigue siendo una alternativa de menor costo y mayor precisión. La desviación semanal de AP de prueba del ganador es 0.077365, señal de variación temporal; no es un intervalo de confianza iid. Ajuste: 16.45 s; tamaño: 576,458 bytes; latencia: 0.002800 ms/fila.

La prevalencia pasa de 1.67% en validación a 2.18% en prueba. Las ventanas se solapan y no son incidentes independientes. El snapshot de capacidad de septiembre no representa su historia completa. Estos resultados respaldan una evaluación académica del proxy y no permiten cuantificar el costo del rebalanceo.

Cisco Confidential

5 P3 Grupos de estaciones

Baseline: K-Means, k=6 seleccionado en train. Candidatas: PCA de ocho componentes + K-Means con k=3/4/6. Escalado y PCA se ajustan solo con train. Para comparar silhouette y Davies-Bouldin se usa siempre el espacio original de 50 variables escaladas con train, incluidas las candidatas que agrupan en el espacio PCA.

Modelo	Sil train	Sil val	Sil test	DB val	DB test	Delta Sil val
Baseline KMeans k=6	0.083076	-0.163812	0.079846	2.796635	2.885608	+0.000000
PCA8 + KM k=3	0.084754	-0.041906	0.076440	3.734053	3.288847	+0.121906
PCA8 + KM k=4	0.085674	-0.041906	0.076440	3.734053	3.288847	+0.121906
PCA8 + KM k=6	0.051748	-0.209371	0.049053	3.307668	3.141645	-0.045559

Modelo	ARI semillas medio	ARI semillas mínimo	ARI temporal val	ARI temporal test
Baseline KMeans k=6	0.452768	0.439921	0.470257	0.546885
PCA8 + KM k=3	0.845614	0.751318	0.395780	0.500452
PCA8 + KM k=4	0.782277	0.782277	0.395737	0.500362
PCA8 + KM k=6	0.735976	0.643189	0.350984	0.377656

P3 no tenía validación/prueba temporal en la primera entrega: se añade este diagnóstico, manteniendo las métricas originales de train y sus valores. La comparación entre periodos usa las estaciones válidas comunes con train: 424 en train y 422 en validación/prueba. Coordenadas solo se utilizan en el mapa.

Se elige PCA8 + K-Means k=4. Su silhouette de validación (-0.041906) supera al baseline (-0.163812) en 0.121906 puntos. k=3 empata en silhouette; k=4 gana por ARI mínimo entre semillas (0.782277 frente a 0.751318). Se comparan semillas 42, 43 y 44. El silhouette de prueba es 0.076440 frente a 0.079846 del baseline: no mejora en todas las métricas.

La separación negativa en validación y ARI temporal de 0.395737 muestran que la segmentación no está consolidada. Se registra champion para el ciclo de vida académico, con esta limitación explícita. Antes de usar grupos para decisiones reales deben revisarse perfiles, estacionalidad y cobertura de estaciones. Ajuste: 0.0098 s; tamaño: 9,369 bytes; latencia: 0.001233 ms/fila.

Cisco Confidential

6 Artefactos selección y ciclo de vida

Cada corrida conserva etiquetas question, model_family, stage_of_work, equipo, git_commit y data_version. La suite tiene una corrida Project, cuatro hijas baseline y tres padres search-pN, cada uno con tres hijas candidatas. La suite final se identifica por sus IDs; los intentos fallidos quedan fuera de la selección.

Ubicación	Contenido
Modelo MLflow 3	Estimador completo, firma, ejemplo numérico y dependencias; enlazado a la corrida mediante model_uri.
config/	run_config.json, entorno.json, config.py, MLproject, python_env.yaml y requirements.txt.
data/ e inputs	Manifiesto de ingesta; esquema y digest de datasets agregados mediante log_input.
plots/	P1: real/predicho y residuales. P2: confusión y precisión-recall. P3: mapa y perfiles horarios.
results/	Resumen, selección de umbral, estabilidad semanal o diagnósticos de grupos.

Se usan aliases en lugar de etapas clásicas: champion es una referencia estable a una versión y permite cambiar la versión de consumo sin modificar el nombre usado por los clientes (MLflow, s. f.-e). La etapa clásica aparece como None porque la producción de esta entrega se expresa con el alias.

models:/mibici-equipo27-p1-demanda@champion · versión 1

models:/mibici-equipo27-p2-riesgo@champion · versión 1

models:/mibici-equipo27-p3-grupos@champion · versión 1

El registro comprueba la presencia de carpetas de artefactos e inputs, el experimento, los cortes, las métricas y la concordancia de etiquetas de linaje con el resumen. Reutiliza una versión que ya provenga de la misma corrida. Comprueba predicciones por URI de origen, por número de versión y por alias usando el ejemplo guardado. Si falla la comprobación posterior al cambio de alias, restaura el anterior para ese modelo. No constituye una transacción conjunta de tres aliases.

Las tres cargas por alias y las tres paridades fueron verificadas con cinco entradas de ejemplo por modelo. Esto comprueba integración y contrato de entrada; no sustituye una evaluación con tráfico real. No se desplegó un endpoint de inferencia; el alcance es la promoción y carga local por alias.

Cisco Confidential

7 Linaje y colaboración pendiente

mibici-equipo27-p1-demanda · v1 @champion

Run origen: 683b78f7fe9643be9b7496a77c951e58

mibici-equipo27-p2-riesgo · v1 @champion

Run origen: 8f8989795a434fb8960b4f4ce13fa9cb

mibici-equipo27-p3-grupos · v1 @champion

Run origen: 5a0f7131eee545758051e4411542af0e

Experimento: mibici-equipo27. Commit común de entrenamiento: 9cd40eb0af9feed8bcbf6048a74292e04b8709c2

Commit que ejecutó la promoción: 24e7852b25a16292b4967009a60c515a0ff43ee2

Run de registro verificado: 39e56e8397a744138f03d57715ce5d45

La versión de datos completa coincide con la mostrada en la sección 1. Los archivos experiment_results.json y registry_results.json conservan los IDs íntegros, las métricas y los criterios de selección. La base SQLite y mlartifacts se conservan solo en la copia de trabajo local y deben reconstruirse al reproducir desde Git.

La comprobación del código compara las etiquetas de las corridas con el resumen de resultados. Los commits anteriores se conservan tal como aparecen en los JSON y en las capturas; su disponibilidad en el historial Git consultado sigue pendiente de aclaración. No se sustituyen por commits actuales, porque ello alteraría el linaje de la ejecución documentada.

Componente	Integración	Estado al preparar el reporte
Parte A	feat/mlflow-project hacia main	Integrada mediante PR #10 (https://github.com/hespinola/TC5061-Proyecto-Equipo27/pull/10).
Parte C	feat/mlflow-registry hacia feat/mlflow-experiments	Integrada mediante PR #12 (https://github.com/hespinola/TC5061-Proyecto-Equipo27/pull/12).
Parte B con C incorporada	feat/mlflow-experiments hacia main	Revisión e integración pendientes.

Antes de entregar, debe actualizarse el estado de los PR y comprobarse que cada integrante abrió al menos un PR y revisó al menos uno en esta entrega. También queda pendiente confirmar la protección de main y el acceso del profesor. Estos requisitos no se presentan como completados.

Cisco Confidential

8 Evidencia búsquedas anidadas

Captura de la ejecución original: jerarquía de la búsqueda de P1 y sus tres combinaciones. La vista contiene corridas con distintos estados y un intento fallido; no demuestra por sí sola la finalización de la suite. El resumen final identifica las corridas usadas para la comparación y el registro.

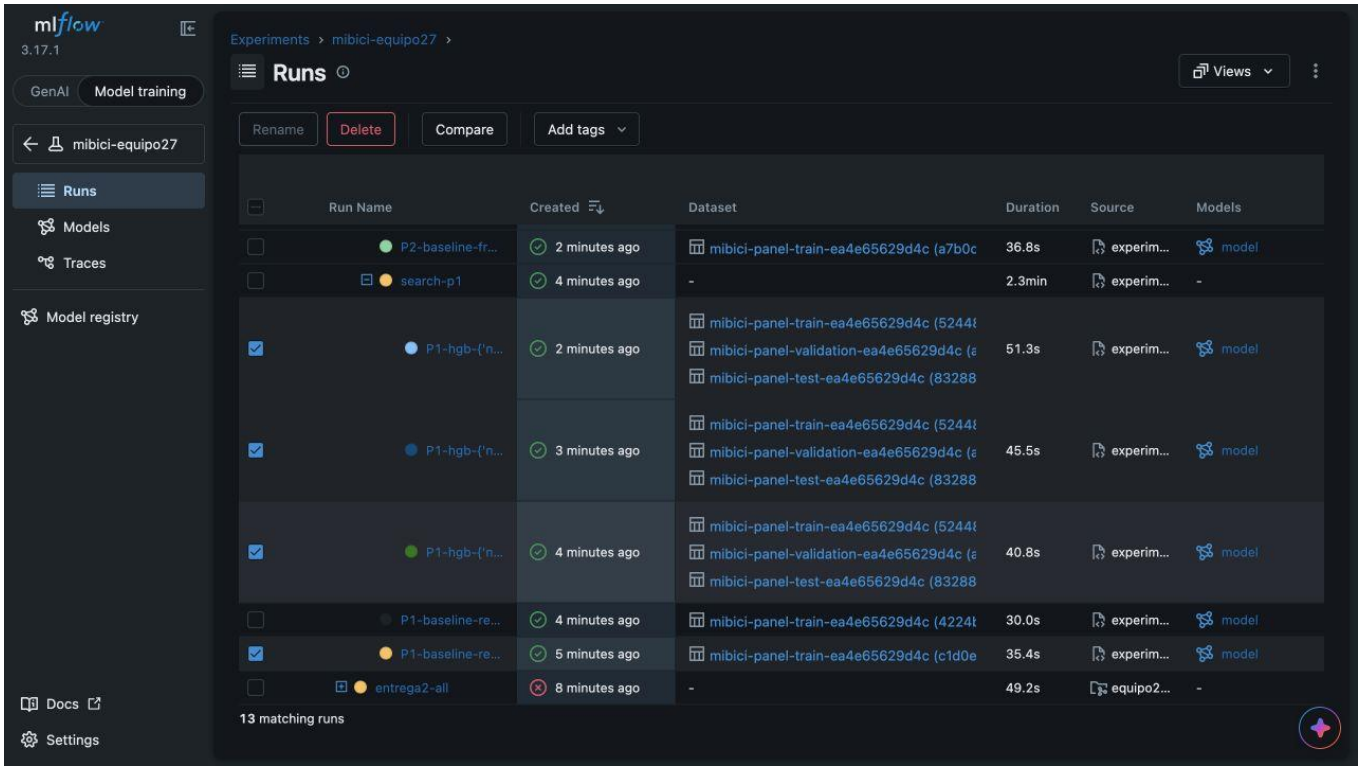


Figura 2. Búsqueda anidada de P1 y sus tres combinaciones.

Cisco Confidential

9 Evidencia comparación contra baseline

Comparación real de cuatro runs en el mismo experimento: baseline semanal y tres configuraciones HGB. Los valores completos están en la tabla de P1 y en el JSON de resultados.

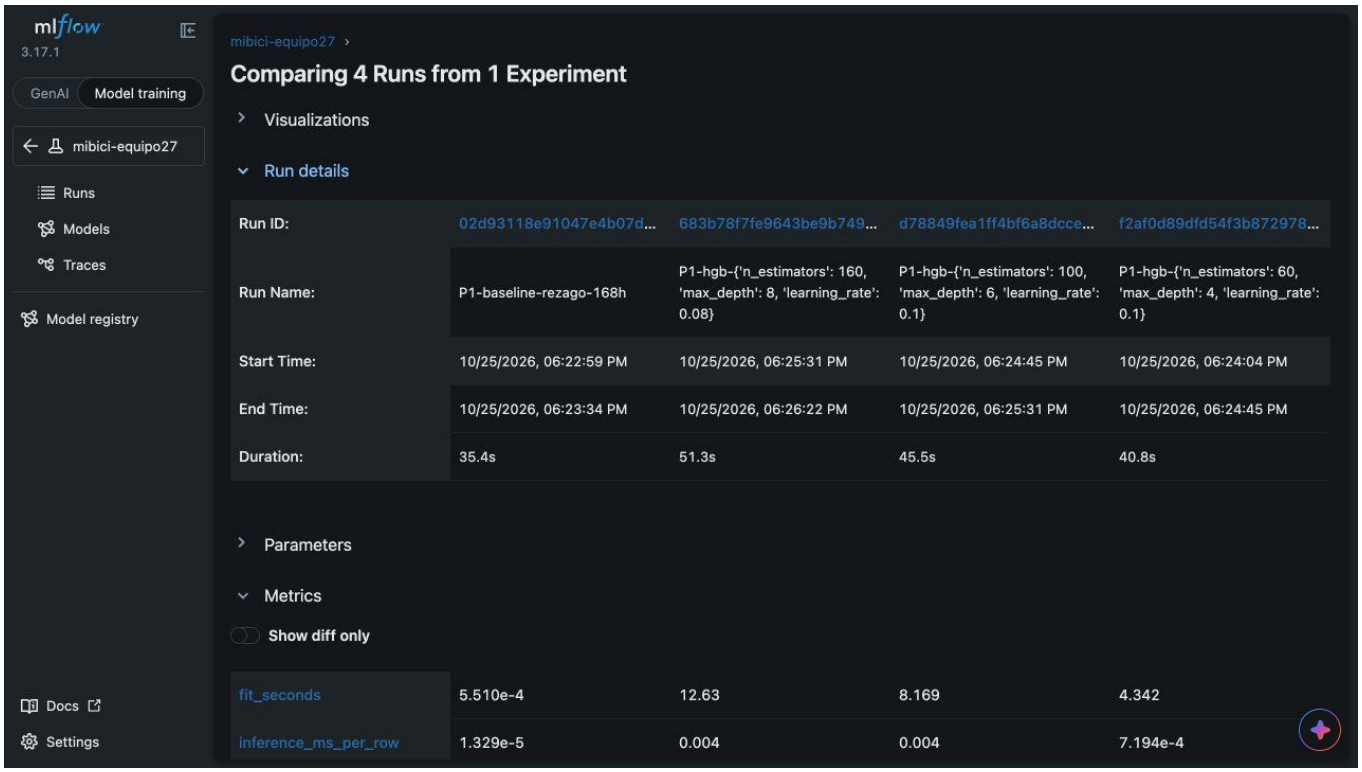


Figura 3. Comparación del baseline semanal y tres candidatas de P1.

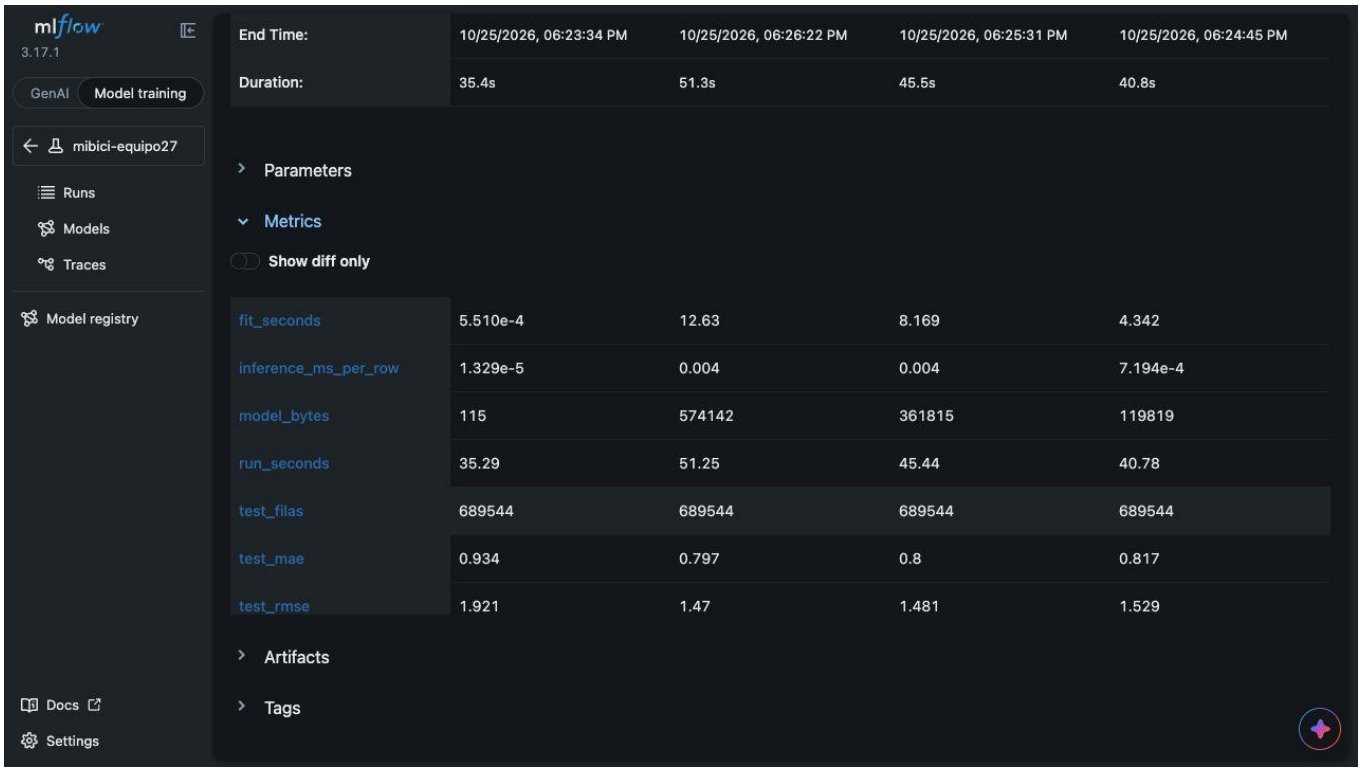


Figura 4. Métricas de prueba de las cuatro corridas comparadas.

Cisco Confidential

10 Evidencia artefactos y datos

Corrida candidata de P1: configuración, manifiesto de datos y gráficas organizadas por carpeta. MLflow 3 presenta el modelo en Logged models, enlazado a esta corrida.

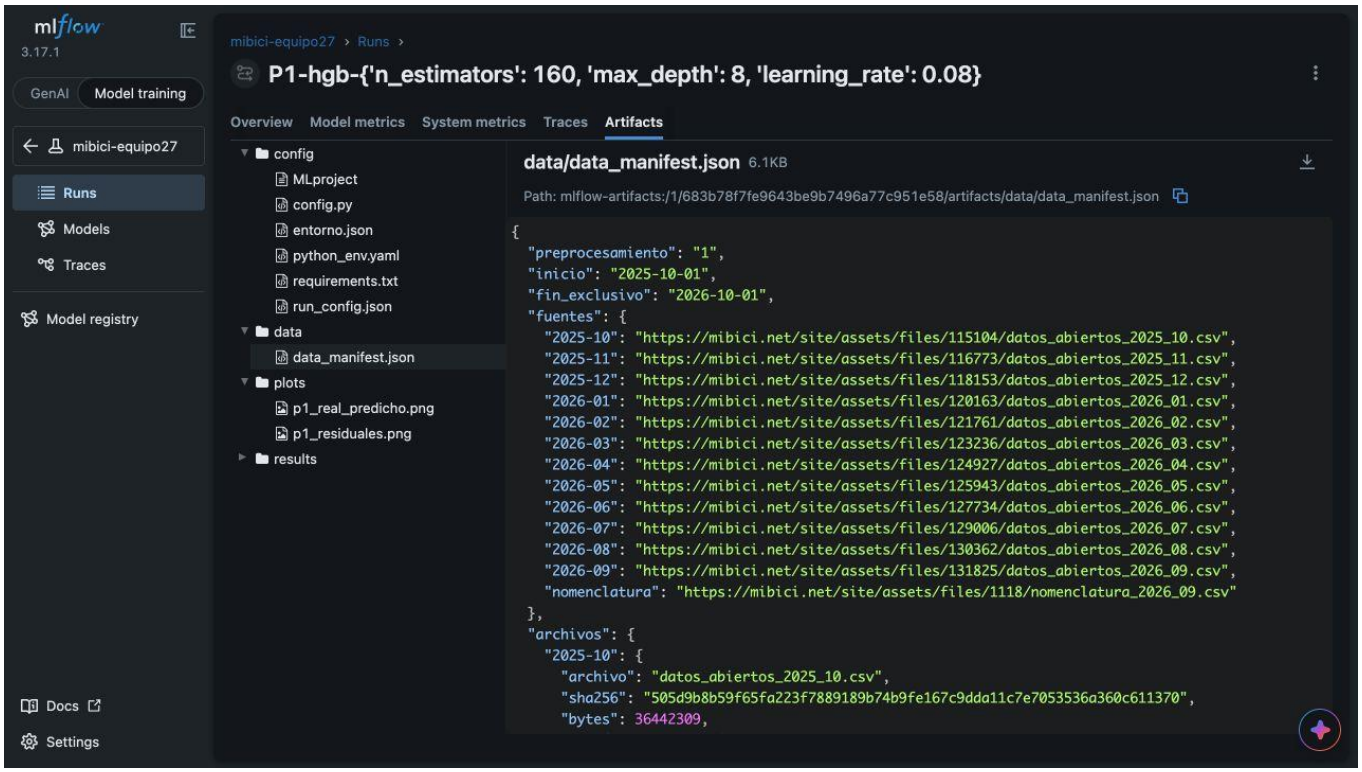


Figura 5. Artefactos de configuración datos y desempeño de una candidata.

Cisco Confidential

11 Evidencia tres modelos en producción

Los tres modelos aparecen en Model Registry con versión 1 y alias champion.

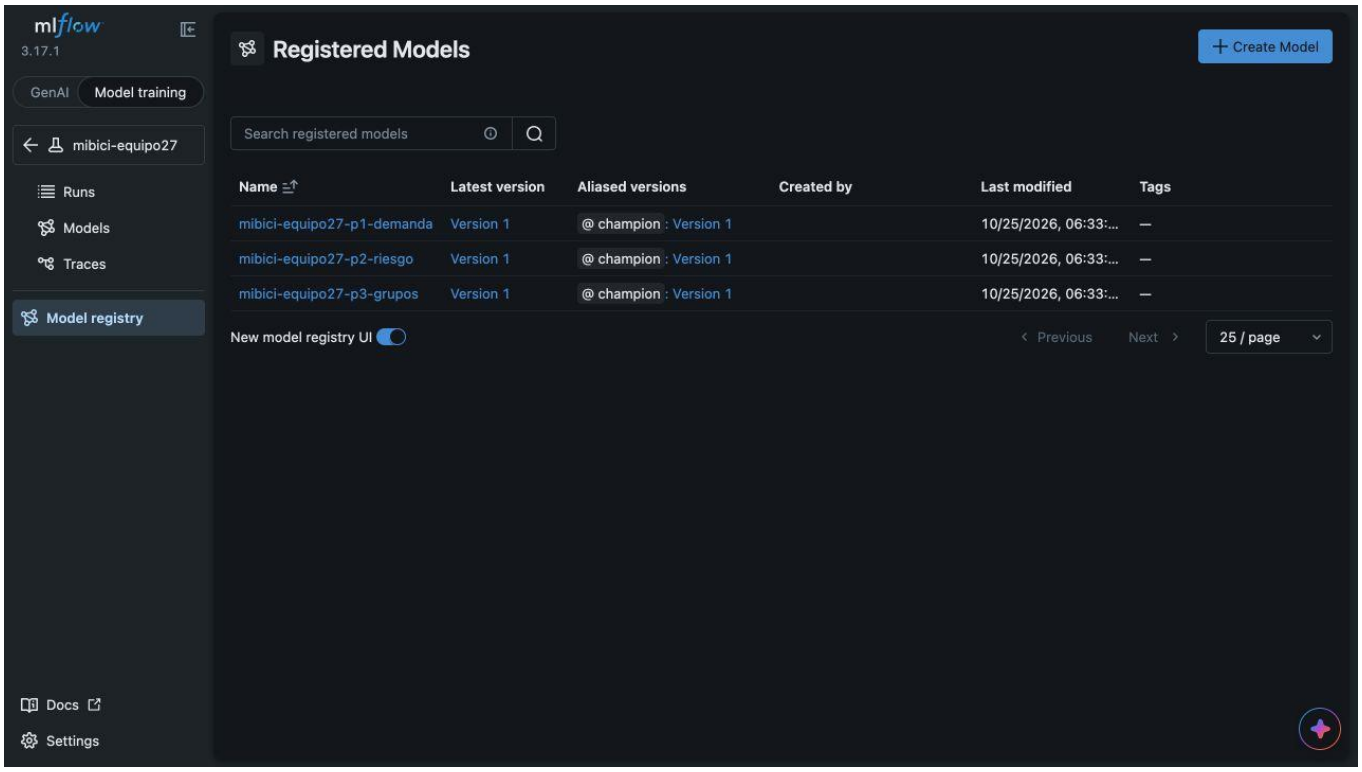


Figura 6. Tres modelos registrados con versión 1 y alias champion.

Cisco Confidential

12 Evidencia linaje de P1

La versión de P1 conserva corrida origen, alias, commit y versión de datos.

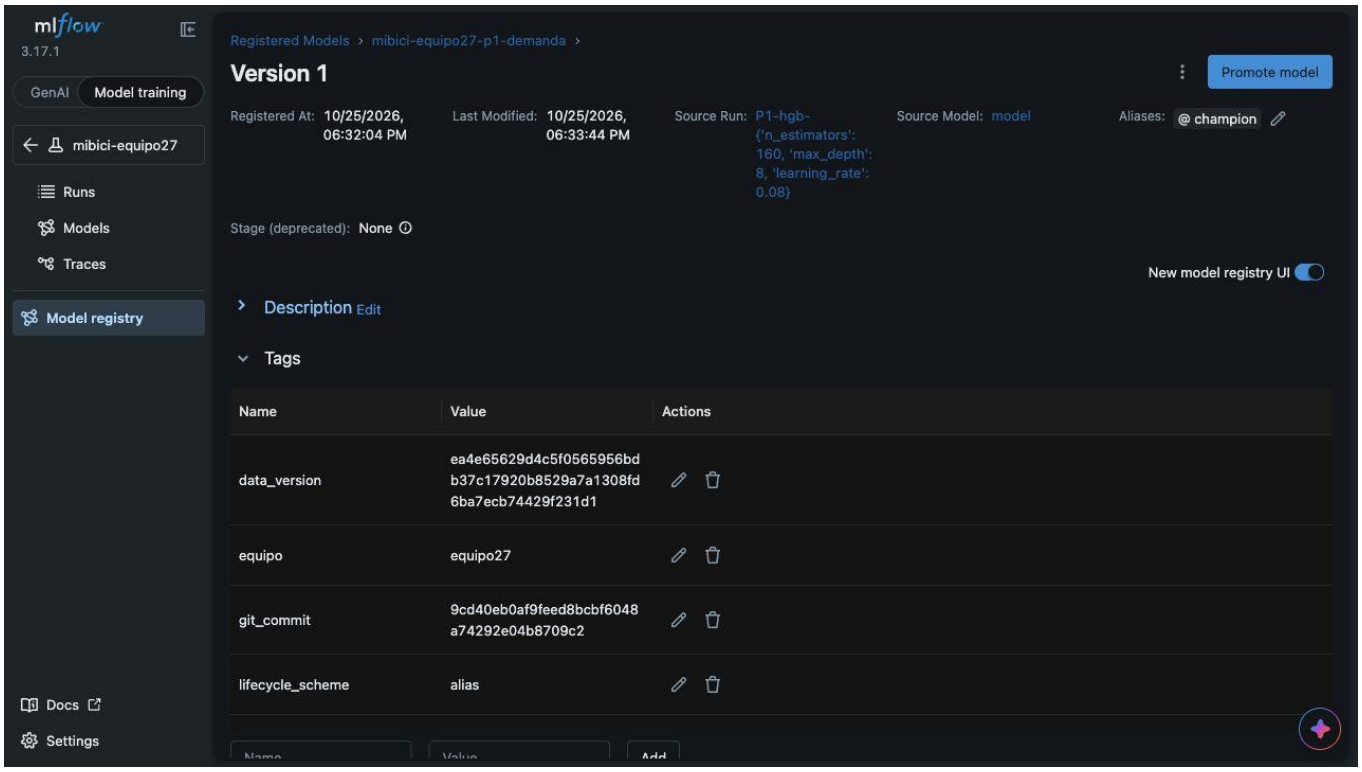


Figura 7. Linaje registrado del modelo de demanda P1.

Cisco Confidential

13 Evidencia linaje de P2

La versión de P2 conserva corrida origen, alias, commit y versión de datos; el estimador incluye umbral 0.20.

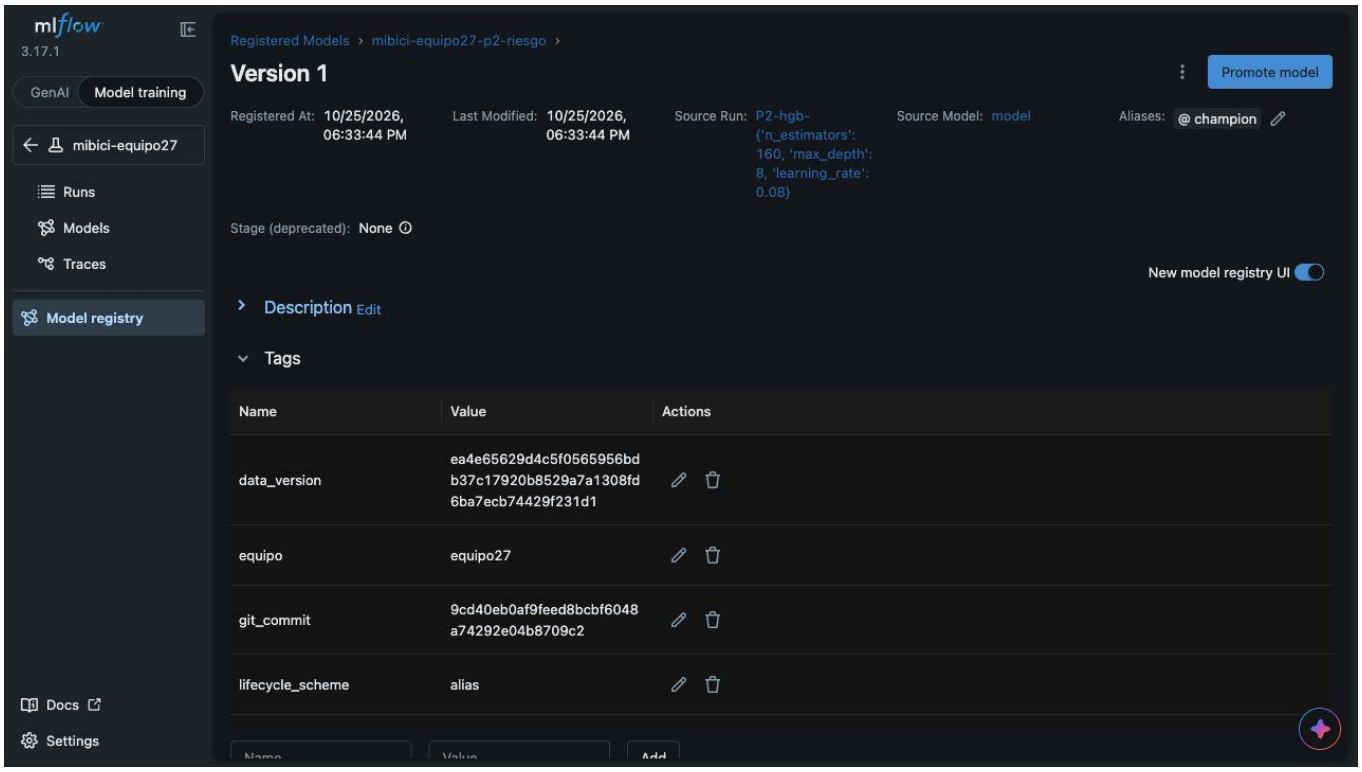


Figura 8. Linaje registrado del modelo de riesgo P2.

Cisco Confidential

14 Evidencia linaje de P3

La versión de P3 conserva corrida origen, alias, commit y versión de datos; la descripción limita su interpretación operativa.

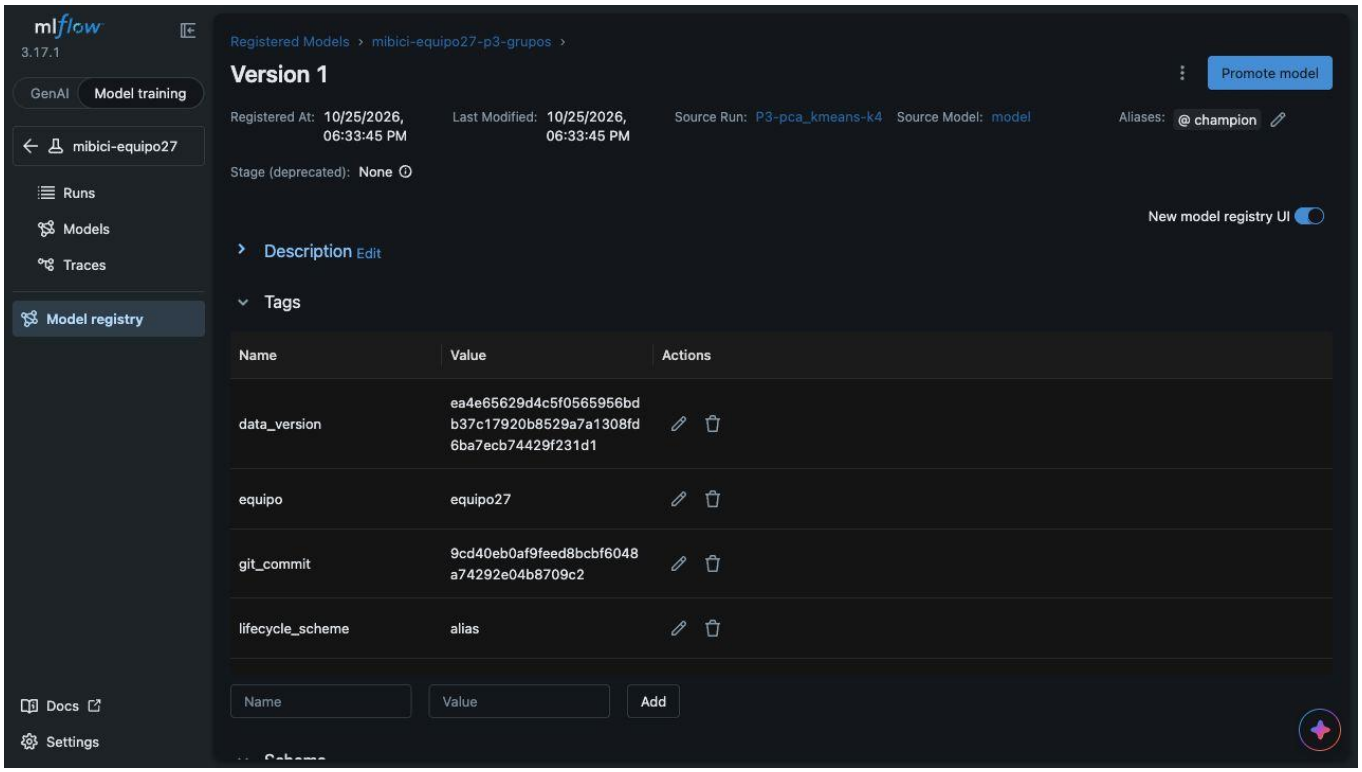


Figura 9. Linaje registrado del modelo de grupos P3.

Cisco Confidential

15 Conclusiones

El flujo permite repetir la experimentación desde MLflow Project y conservar artefactos, parámetros, versión de datos y modelos seleccionados. Las búsquedas incorporan tres candidatas por pregunta, mientras que la selección evita usar las métricas de prueba.

P1 ofrece la evidencia más clara de mejora predictiva, con una reducción de MAE de prueba de 14.60% frente al baseline semanal. P2 mejora recall y F1 en prueba, pero reduce precisión y AP; su conveniencia depende de la tolerancia a falsas alertas. P3 mejora la separación de validación frente al baseline y permite evaluar estabilidad, aunque el silhouette negativo señala que la segmentación necesita refinamiento.

El alias champion cumple el mecanismo de producción académica solicitado y permite cargar los modelos por un nombre estable. El registro no equivale a un servicio desplegado ni demuestra beneficios operativos. El cierre de la entrega requiere completar la revisión colaborativa y aclarar la recuperación de los commits de origen.

16 Referencias

Equipo 27. (2026). *TC5061-Proyecto-Equipo27*. [Repositorio de código y manifiesto de datos]. GitHub. https://github.com/hespinola/TC5061-Proyecto-Equipo27

MLflow. (s. f.-a). *MLflow Dataset Tracking*. Recuperado el 25 de octubre de 2026, de https://mlflow.org/docs/latest/ml/dataset/

MLflow. (s. f.-b). *MLflow Projects*. Recuperado el 25 de octubre de 2026, de https://mlflow.org/docs/latest/ml/projects/

MLflow. (s. f.-c). *mlflow.sklearn*. Recuperado el 25 de octubre de 2026, de https://mlflow.org/docs/latest/api_reference/python_api/mlflow.sklearn.html

MLflow. (s. f.-d). *MLflow Tracking APIs*. Recuperado el 25 de octubre de 2026, de https://mlflow.org/docs/latest/ml/tracking/tracking-api/

MLflow. (s. f.-e). *Model Registry Workflows*. Recuperado el 25 de octubre de 2026, de https://mlflow.org/docs/latest/ml/model-registry/workflow/

MLflow Projects respalda el empaquetado y los puntos de entrada (s. f.-b); Tracking APIs, el registro explícito de métricas y corridas (s. f.-d); Dataset Tracking, el linaje de inputs (s. f.-a); Model Registry Workflows, aliases y almacenamiento con base de datos (s. f.-e); y mlflow.sklearn, el registro del modelo con firma y ejemplo (s. f.-c). Las cifras y conclusiones del reporte derivan de las ejecuciones locales del equipo, no de la documentación.

Archivos de evidencia: reports/experiment_results.json, reports/registry_results.json, reports/baseline_results.json, references/data_manifest.json y reports/figures/entrega2/.

Cisco Confidential