MACHINE LEARNING CANVAS

Designed for: ML-Ops TC5061 Designed by: TC5061-Equipo27 Date: 18/10/2026 Iteration: 2.

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Se desarrollarán tres modelos de ML, uno por pregunta:

- **P1 (regresión):** predecir el número de viajes que comenzarán en cada estación durante la siguiente hora. La predicción se emite al inicio de la hora t y el resultado se observa al terminar esa hora. Entidad: estación × hora.
- **P2 (clasificación binaria):** predecir si una estación presentará un desequilibrio de flujo durante las tres horas que comienzan en t. La etiqueta será 1 cuando el valor absoluto de la suma de llegadas menos salidas durante ese intervalo sea

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Los resultados apoyarán las siguientes decisiones:

- **P1:** identificar estaciones y franjas horarias con mayor demanda prevista para apoyar la planeación de bicicletas disponibles.
- **P2:** generar cada hora una clasificación de estaciones según la probabilidad de desequilibrio futuro. El equipo de rebalanceo podría priorizar las primeras N, de acuerdo con su capacidad de atención. La probabilidad corresponde a la etiqueta de flujo, no a una probabilidad comprobada de quedarse sin bicicletas o

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiario: compañía gestora de MiBici. Cada pregunta tiene un usuario distinto:

- **Operador del sistema (P1):** planear la flota según la demanda esperada.
- **Equipo de rebalanceo (P2):** mover bicicletas antes de que una estación se vacíe o se llene.
- **Planeación urbana (P3):** apoyar la evaluación de estrategias de operación y posibles zonas de expansión

Pain points:

- Estaciones vacías o llenas que hacen perder viajes.
- Rebalanceo reactivo, sin anticipación.
- Poca visibilidad

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Se implementará una ingesta reproducible en dataset.py que descargue los CSV del periodo configurado y la nomenclatura de estaciones, normalice columnas, codificación y fechas, valide los registros y genere archivos Parquet sin pasos manuales.

El proceso registrará archivos descargados, conteos antes y después de la limpieza, duplicados, estaciones sin correspondencia y reglas de exclusión. Las uniones con la nomenclatura deberán conservar el número de viajes y validar que cada identificador corresponda a una sola estación.

Un manifiesto versionado en Git incluirá las URLs, el periodo, los hashes

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Portal oficial de datos abiertos de MiBici (https://mibici.net/es/datos-abiertos/):

- Histórico de viajes, de 2025-10 a 2026-09: identificador del viaje, estaciones de origen y destino, y fecha y hora de inicio y fin.
- Nomenclatura de estaciones 2026-09: identificador, nombre, coordenadas geográficas y capacidad de anclajes.

Los campos personales (id de usuario, género y año de nacimiento) no se usan, y los resultados se reportan agregados por estación.

mayor o igual al 50 % de la capacidad de la estación. Entidad: estación × hora. Esta etiqueta es una aproximación del riesgo operativo; no mide directamente si una estación queda vacía o llena. Tampoco identifica todos los cruces intermedios del umbral, pues utiliza el flujo neto total del intervalo. • **P3 (clustering):** agrupar estaciones con perfiles de uso similares, considerando distribución horaria de salidas entre semana y fin de semana, volumen diario y balance entre llegadas y salidas. Entidad: estación. Los perfiles se construirán únicamente con el periodo de entrenamiento.	anclajes. • **P3:** identificar estaciones con patrones similares para apoyar estrategias diferenciadas de operación y formular hipótesis de planeación. Los grupos, por sí solos, no justifican instalar estaciones nuevas. En esta entrega, las recomendaciones se ilustran mediante tablas, gráficas y mapas sobre datos históricos; no se ejecutarán acciones operativas.	sobre qué zonas se usan de forma parecida.	SHA-256 y los conteos de cada archivo. Su identificador se registrará en MLFlow. Los archivos originales se conservarán fuera de Git para recuperar la misma versión si cambia la fuente. La incorporación de meses nuevos requerirá actualizar las URLs y el periodo en config.py. El sistema utilizará publicaciones mensuales; no contará con una fuente de viajes en tiempo real.	

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

La partición será temporal, sin barajar:

Entrenamiento: octubre de 2025 a junio de 2026.

Validación: julio de 2026.

Prueba: agosto y septiembre de 2026.

Cada etiqueta deberá observarse completamente dentro de su partición. Para P2 se excluirán las últimas dos horas de cada partición cuando su ventana de tres horas cruce el límite. Se conservará el contexto histórico anterior necesario para calcular los rezagos.

Los modelos, hiperparámetros, umbrales de clasificación y reglas de priorización se seleccionarán sin consultar el conjunto de pruebas. Este se reservará para la evaluación final.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Se realizará una simulación histórica por lotes. Al inicio de cada hora t, P1 estimará las salidas durante esa hora y P2 el desequilibrio durante las tres horas que comienzan en t. Se utilizarán únicamente los viajes finalizados o iniciados, según corresponda a cada variable, antes de t.

P3 se calculará con los perfiles del periodo de entrenamiento.

La ejecución será local mediante scripts del módulo mibici. Se registrará el tiempo de ejecución y los recursos del entorno utilizado. Una operación real con actualizaciones horarias requeriría una fuente adicional de datos recientes.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Se implementará un baseline por pregunta y se propondrá al menos un modelo candidato:

P1: baseline de demanda de la misma hora de la semana anterior; candidato de gradient boosting.

P2: baseline de frecuencia histórica de la etiqueta de riesgo por estación y hora, calculada exclusivamente con entrenamiento. Si una combinación no tiene antecedentes, se utilizará la frecuencia global de entrenamiento. Candidatos: regresión logística o gradient boosting.

P3: baseline K-Means y candidato de clustering jerárquico. La comparación utilizará las mismas variables, periodo y transformación de datos.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Se construirá un panel estación × hora con salidas, llegadas y flujo neto, incluyendo horas sin viajes.

Las variables predictoras incluirán:

Calendario: hora, día de la semana, fin de semana y codificación cíclica. Los festivos se incorporarán únicamente si se documenta su fuente.

Rezagos de 24 y 168 horas y promedios móviles calculados exclusivamente con horas anteriores a t.

Para P2: capacidad de la estación y flujo neto acumulado del día hasta antes de t, relativo a su capacidad.

Para P3: perfiles horarios de salidas entre semana y fin de semana, volumen diario y balance entre llegadas y salidas, calculados con entrenamiento.

Se plantea como hipótesis que omitir una estación con desequilibrio resulta más costoso que emitir una alerta innecesaria. Como no se dispone de costos operativos ni inventarios reales, no se afirmarán ahorros económicos ni reducciones comprobadas de estaciones vacías o llenas. El objetivo de esta entrega es establecer baselines reproducibles y documentar su desempeño. Superarlos será un objetivo de las siguientes entregas. No se realizará un despliegue operativo.			Para P3 se escalarán las variables para evitar que el volumen o las unidades dominen las distancias. Inicialmente, las coordenadas se utilizarán para visualizar los grupos; su incorporación al agrupamiento se evaluará como un experimento separado. Se documentará la elección del número de grupos, su separación, estabilidad e interpretación operativa. Los transformadores se ajustarán únicamente con entrenamiento. Cada ejecución registrará configuración, versión de datos, semilla, commit, métricas y artefactos en el experimento mibici-equipo27 de MLFlow.	Las salidas, llegadas y el flujo neto de la hora objetivo, así como las etiquetas futuras, no se utilizarán como predictores de P1 o P2. La capacidad de septiembre de 2026 se tratará como una aproximación fija para el periodo histórico. Se documentará esta limitación y se identificarán estaciones sin capacidad válida o sin correspondencia en la nomenclatura. El flujo acumulado diario se interpretará como una medida de desequilibrio, no como inventario estimado.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

La evaluación experimental incluirá:

P1: MAE y RMSE.

P2: recall, precisión, F1 y average precision, además de la proporción observada de casos positivos. El umbral se seleccionará en validación y quedará fijo para prueba.

P3: silhouette y Davies-Bouldin, acompañados de tamaños de grupos, estabilidad e interpretación de sus perfiles.

Las métricas se identificarán según la partición utilizada, por ejemplo, validation_mae y test_mae. El desbalance de clases se verificará con los datos; no se asumirá antes de medirlo.

Si posteriormente se desplegara el sistema, se vigilarían la cobertura de estaciones, los datos faltantes, los cambios en la distribución de variables y el desempeño sobre periodos nuevos. Las

	métricas de P2 evaluarían el proxy de desequilibrio; comprobar su impacto operativo requeriría información adicional de inventario y rebalanceo.	

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Whatever you can't answer is the work left before anyone writes code.

Book a project review

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

Book a 30-minute call →

Reference the Machine Learning Canvas

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```

"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."

"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."

— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

— Daitan, now part of Coforge, a global IT services firm